从槽位读数到粗细粒度视觉搜索
GUI Grounding 复现、外推与算法实验技术报告

GUI Grounding 实验复现与扩展

2026 年 11 月

摘要

本报告系统整理 GUI-Decisions 槽位读数方法的复现、自然图像外推及高分辨率 GUI grounding 改进实验。所有新增测量均基于 GUI-Decisions-2B 和本地 CPU 推理，不使用远程推理服务。原始 ScreenSpot 全量点命中率为 76.49%，与文章报告值一致；RefCOCO 随机目标零样本点命中率达到 91.41%，但小目标降至 75.78%。在更困难的 ScreenSpot-Pro 上，全图槽位读数仅为 13.41%，768px 裁剪与 KDE-grid 达到 47.88%。本轮进一步在独立的 791 条留出样本上验证：全图到 768px 再到 512px 的顺序缩放达到 50.95%，双 768px 视图经无标签置信度选择达到 52.34%，相对单视图基线提高 3.92 个百分点（McNemar $p = 9.26 \times 10^{-6}$）。针对独立轴缺少二维联合分布的问题，条件链式读取、完整/低秩联合头及线性头均未超过独立轴基线，说明该问题不能靠简单重排现有槽位或小样本冻结头解决，需要更大规模的直接二维空间训练和候选验证机制。

1 研究目标与结论摘要

本文回答五个问题：（1）文章的槽位读数结果能否在本地复现；（2）该接口能否零样本外推到自然图像指代表达定位；（3）在高分辨率、密集专业 GUI 上，误差主要来自坐标读出还是视觉输入；（4）能否在不重新训练的情况下提高准确率，并量化额外计算成本；（5）独立 x/y 槽位的二维联合分布缺失能否通过条件读取或轻量联合监督解决。

主要结论如下。

- 复现成立。 ScreenSpot 全量 default 读数为 76.49%（973/1272），接近文章的 77.0% 及模型卡本地值 76.3%。
- 零样本迁移成立，但不是普遍解决。 RefCOCO 点定位显著优于 vanilla，小目标明显下降；该协议不同于文章附录的框 IoU，不能直接比较。
- 真实局部视觉是最强改进来源。 ScreenSpot-Pro 全量从 13.41% 提升至 40.73%（512px default），再到 47.88%（768px KDE-grid）。
- **KDE** 有独立价值，但不能替代局部视觉重读。全图 KDE-grid 无额外模型前向提升 4.55 个百分点；局部 KDE-grid 与 768px 裁剪结合后收益更大。
- 双视图取得本轮最高留出精度。双 768px 视图达到 52.34%，高于顺序缩放的 50.95%，但两者的直接配对差异不显著（$p = 0.338$），不能据此断言双视图必然优于顺序缩放。
- 复杂门控并非普遍有效。 ScreenSpot-Pro 上 1576/1581 个样本仍被判定需要裁剪，几乎不节省计算；全分布方差驱动的自适应窗口也不如固定窗口。
- 问题 **1** 尚未获得可部署解法。条件联合 KDE 在 128 条 pilot 上为 14.06%，低于独立轴 KDE 的 15.62%；$x + y$ 冻结特征联合头留出为 5.69%，低于独立轴头的 6.70% 和原 default 的 13.91%。

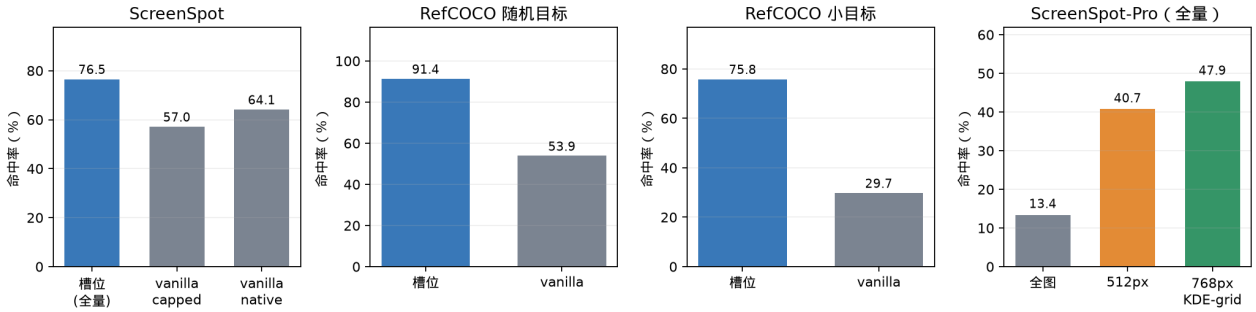


图 **1:** 核心结果概览。ScreenSpot 的 vanilla 与配对槽位比较使用同一 128 条子集，槽位全量柱仅作背景；RefCOCO 为 128 条；ScreenSpot-Pro 三种方法均为全量 1581 条。

2 实验设置

2.1 模型、数据与运行环境

基础代码为官方 `infinitylogesh/gui-decisions` 的提交 `4afc7f2`，实验脚本和数据分析在工作区中新增。主要模型为 `infinitylogesh/GUI-Decisions-2B`（快照 `c2cedfd`），vanilla 对照为 `mPLUG/GUI-Owl-1.5-2B-Instruct`（快照 `528ceae`）。

表 **1:** 数据集与用途

数据集	样本量	协议与用途
ScreenSpot	1272	原始点击框内命中率，全量复现；vanilla 使用 `id % 10 == 0` 的 128 条配对子集。
RefCOCO val	8415 个去重目标	按 COCO 图像 ID 与框去重，XYWH 转 XYXY 并裁剪到 $[0,1]$；每个目标取 `answer[0]`，提示为'click + expression'。
RefCOCO 小目标	170 个候选，抽样 128	面积 < 0.05；全集中最小面积仍约为 0.0305，不能代表极小物体。
ScreenSpot-Pro	1581	高分辨率专业软件、完整屏幕；点落入 GT 框计为正确。覆盖 23 个应用、6 个类别及文本/图标目标。

所有实验使用 CPU，环境为 Python 3.12、PyTorch 2.15、Transformers 5.22.1，线程设置为 `OMP_NUM_THREADS=96` 和 `MKL_NUM_THREADS=96`。模型图像上限保持训练配置（GUI-Owl 为 1MP）；局部裁剪从原图取得，再经过相同处理器。报告中的延迟均为本地 CPU 中位数，不能用于验证文章的 **RTX PRO 6000 GPU** 加速比。

2.2 指标与统计方法

主要指标是点落入 GT 框的比例（Hit@1）。RefCOCO 另报告中心接近率：预测点与框中心在两个归一化轴上的距离均不超过 0.1；中心距离为归一化欧氏距离中位数。配对提升使用 10000 次 paired bootstrap 的 95% 区间，二元命中差异使用双侧精确 McNemar 检验。解析失败计为错误；延迟包含相应模型前向，不把未执行的读取计入。

ScreenSpot-Pro 的算法选择严格划分为前 790 条校准样本与后 791 条留出样本（源样本已用 seed 0 随机打乱）。尺寸与局部读出仅在校准集选择，留出集只执行预选组合；已有 512px default 作为配对参照。

3 槽位读数与分布近似

槽位方法在每个答案位置直接读取下一 token 分布，不生成 JSON 坐标。每个轴离散为 256 个 bin。default 读取最大 bin 并用相邻 ± 2 个 bin 做概率加权；peak 仅取最大 bin；expected 取全分布期望。

对空间搜索，实验额外考察独立轴外积近似：

$$q_{ij} = p_x(i)p_y(j), \tag{1}$$

其中 q_{ij} 只是二维联合分布的近似，并非模型直接输出的联合概率。region voting 将空间划为 16×16 区域并选择最大概率质量区域；sampled KDE 从两个轴独立采样 64 个点并选取核密度峰；KDE-grid 在外积网格上用带宽 0.03 的二维 Gaussian 平滑，再在峰值邻域加权读出。该近似可能把真实的两个二维模态扩展为四个组合，因此其收益必须实测。

4 原始 ScreenSpot 复现

4.1 全量槽位结果

表 **2:** ScreenSpot 全量结果（$n = 1272$）

读出	命中数	命中率	Wilson 95% 区间	click 动作准确率
default	973	**76.49%**	[74.09%, 78.74%]	93.79%
peak	968	76.10%	[73.68%, 78.36%]	93.79%
expected	754	59.28%	[56.55%, 61.94%]	93.79%

default 与 peak 接近，说明局邻域加权只有小幅影响；expected 显著较差，表明坐标分布存在多峰或长尾，期望会落到候选之间。文章报告值为 77.0%，模型卡本地值为 76.3%，本结果处于合理复现范围。

4.2 vanilla 配对对照

表 **3:** 同一 128 条 ScreenSpot 子集的配对比较

方法	命中率	槽位相对提升	McNemar p
槽位 default	78.12%	—	—
vanilla，相同 capped 图像	57.03%	+21.09 pp	1.43×10^{-5}
vanilla，native 图像	64.06%	+14.06 pp	0.00510

CPU 中位延迟分别为：vanilla capped 5.76s、native 11.08s；槽位全量运行时约 1.52s。vanilla 使用原文 agent/tool-call 提示词，不是 **GUI-Owl** 专用 **grounding** 提示词，因此该对照证明的是相同 agent 协议下的差异，不是所有提示词条件下的最优公平排名。

5 自然图像零样本外推

5.1 随机目标

表 **4:** RefCOCO 随机 128 个目标（seed 0）

方法	框内命中率	中心接近率	中心距离中位数
槽位 default / peak	**91.41%**	53.91% / 54.69%	0.1012 / 0.1010
槽位 expected	85.94%	**72.66%**	**0.0765**
vanilla	53.91%	40.63%	0.1505

default 相对 vanilla 提升 37.50 个百分点，paired bootstrap 95% CI 为 $[28.12, 46.88]$；仅槽位正确 51 条、仅 vanilla 正确 3 条，McNemar $p = 2.92 \times 10^{-12}$。vanilla 有 4 条解析失败，生成长度中位数为 52 tokens。seed 1 的独立 128 条复核中，default 仍为 91.41%，expected 为 86.72%；两组 default 合计 234/256。

default 更适合’落入框内’，expected 的中心估计反而更好。这提示评估指标会改变最佳读出：若目标是框内命中，尖锐模态更有利；若目标是回归中心，期望可能更平滑。

5.2 小目标压力测试

表 **5:** RefCOCO 面积 < 0.05 的 128 个目标（seed 0）

方法	框内命中率	中心接近率	中心距离中位数
槽位 default / peak	**75.78%**	64.84%	0.0615
槽位 expected	60.16%	63.28%	0.0862
vanilla	29.69%	30.47%	0.2281

default 相对 vanilla 提升 46.09 个百分点，95% CI $[36.72, 55.47]$，分歧为 63/4 条，$p = 1.11 \times 10^{-14}$。但槽位自身从随机集合的 91.41% 降至 75.78%，证明小目标仍是明显弱点。典型失败包括复杂关系、位置限定和视觉上不显著的目标。

6 ScreenSpot-Pro：高分辨率 GUI 改进

6.1 全图分布读出与固定裁剪

ScreenSpot-Pro 的目标平均仅占图像约 0.07%，原始 ScreenSpot 约为 2.01%[2]。全量 1581 条结果如下。

表 **6:** ScreenSpot-Pro 全图读出与 512px 固定裁剪（全量 $n = 1581$）

方法	命中率	相对 default	额外模型前向
default	13.41%	—	0
peak	13.22%	-0.19 pp	0
expected	6.58%	-6.83 pp	0
region voting	13.85%	+0.44 pp，不显著	0
sampled KDE	17.58%	+4.17 pp	0
KDE-grid	17.96%	+4.55 pp	0
512px 固定裁剪重读	**40.73%**	**+27.32** pp	1 次

512px 固定裁剪修复 473 条、回退 41 条，提升的 paired bootstrap 95% CI 为 $[24.92, 29.79]$ 个百分点，McNemar $p = 3.34 \times 10^{-94}$。KDE-grid 也有显著但较小的收益：95% CI $[2.78, 6.33]$，$p = 4.48 \times 10^{-7}$。这说明分布读出和视觉分辨率是两个可分离的误差来源。

6.2 自适应窗口与门控的失败

在 128 条跨应用随机样本上，default 居中的固定 512px 裁剪为 35.94%，基于全分布方差的自适应窗口仅为 17.97%。长尾方差会扩大窗口，使局部放大退化为近似全图重读。KDE 居中固定裁剪为 39.06%，相比 default 居中的提升不显著（$p = 0.48$），且回退更多，因此未用于全量。

全图置信度对正确性的留出 AUROC 为 0.802，但最终门控仍触发 1576/1581 次裁剪。换言之，该模型在 ScreenSpot-Pro 上几乎普遍不确定，门控不能带来实际的延迟节省。接受策略分析还表明，执行第二次读取和采用第二次预测必须分别计费和统计。

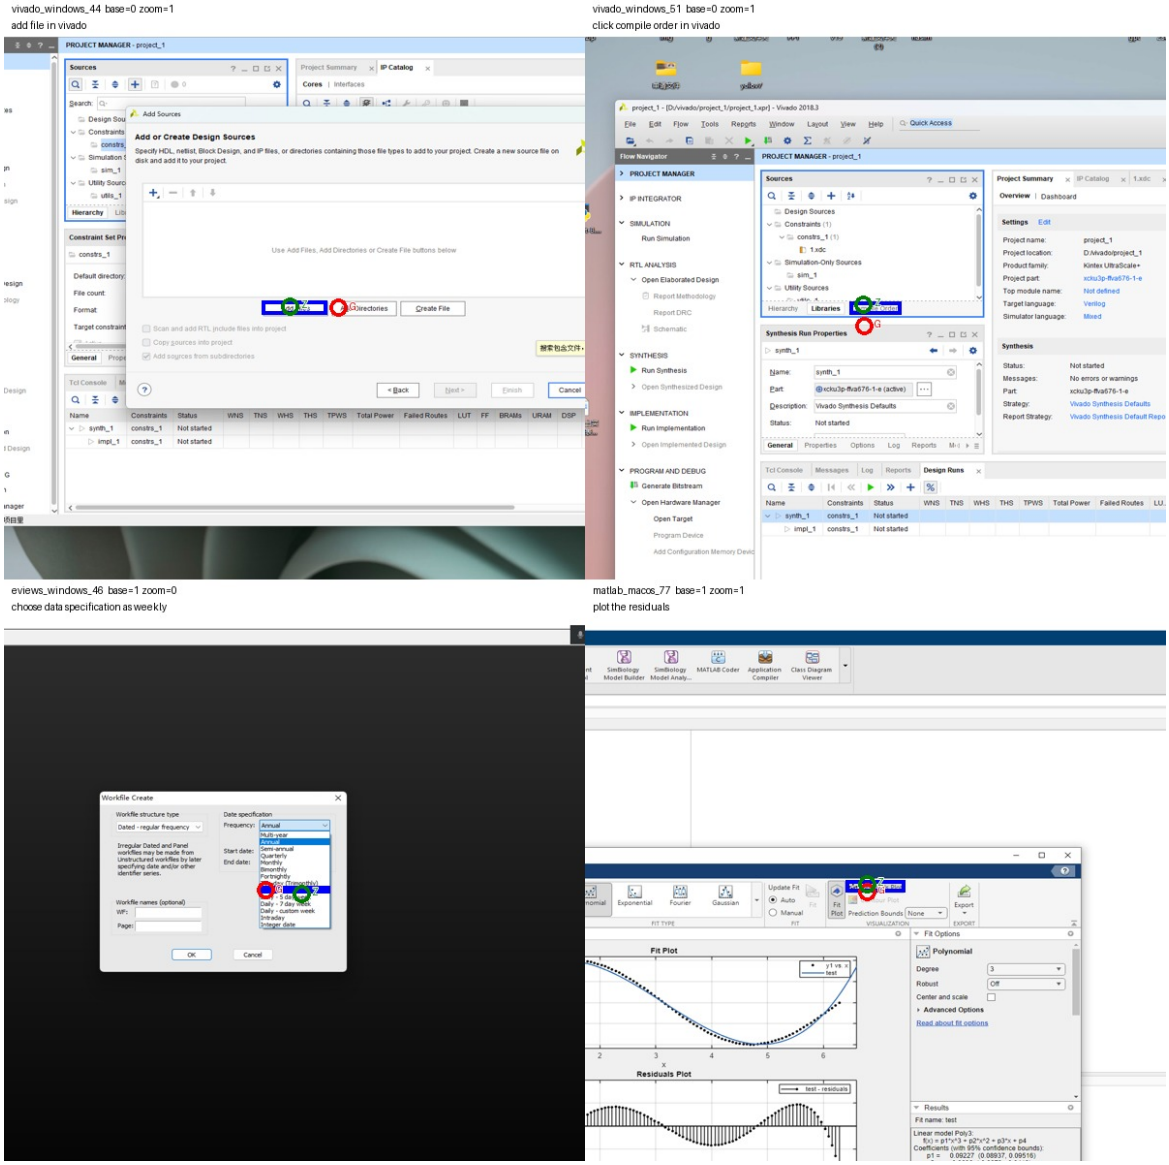


图 **2:** 预测与标注图像抽查。蓝框为 GT，红点 G 为全图结果，绿点 Z 为裁剪结果。上排展示修复，左下展示一次回退，右下为保持正确。坐标映射与标注对齐。

7　裁剪尺寸与局部读出消融

7.1　校准集选择

在前 790 条校准样本上扫描五种方形窗口及四种局部读出。图3显示，KDE-grid 在所有尺寸上均优于 default，768px 达到峰值，1024px 开始下降。

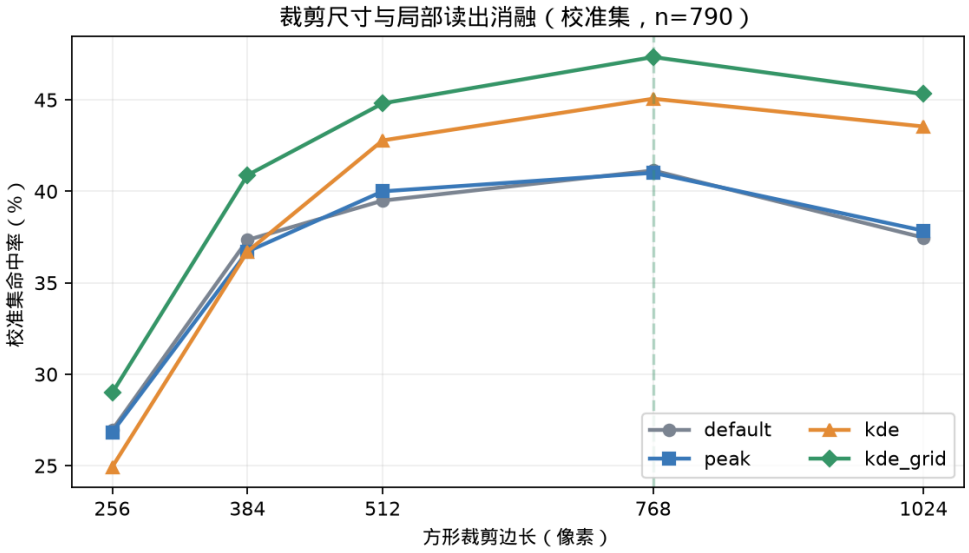


图 **3:** 裁剪尺寸和局部读出消融。选择过程只使用校准集。

相同 512px 下，局部 default 为 39.49%，局部 KDE-grid 为 44.81%，直接提升 5.32 个百分点，95% CI $[3.42, 7.34]$，$p = 1.01 \times 10^{-7}$。768px KDE-grid 相比 512px KDE-grid 再提高 2.53 点，但校准集内 $p = 0.0747$，因此尺寸收益必须依赖留出集确认。

7.2　留出集与合并结果

留出集只执行预选的 768px KDE-grid。

表 **7:** 预选组合的留出验证与全量合并结果

方法	留出集（$n = 791$）	合并（$n = 1581$）	CPU 中位延迟
全图 default	13.91%	13.41%	约 1.44s
512px default	41.97%	40.73%	约 1.91s
768px KDE-grid	**48.42%**	**47.88%**	约 2.38s

留出集上，预选组合相比 512px default 提升 6.45 个百分点，95% CI $[3.67, 9.23]$，$p = 8.29 \times 10^{-6}$；90 条由错转对，39 条由对转错。合并后相对 512px default 提升 7.15 点，95% CI $[5.12, 9.17]$，$p = 7.33 \times 10^{-12}$；相对全图提升 34.47 点，757/1581 个样本正确。

延迟增加约 25%（相对于 512px default 的 CPU 中位延迟），换取 7.15 个百分点的全量准确率提升。KDE 后处理不增加模型前向，主要成本来自更大局部图像的读取。

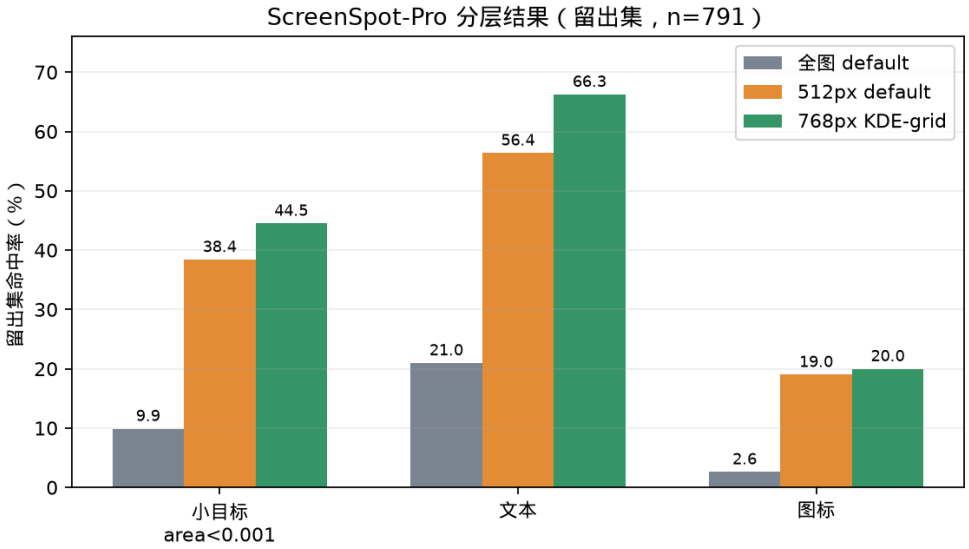


图 **4:** 留出集分层结果。文本和小目标受益显著，图标改善有限。

留出集小目标（面积 < 0.001）从 9.91% 提升至 38.41%（512px default），再到 44.51%（768px KDE-grid）；文本从 20.99% 提升至 56.38% 和 66.26%；图标仅从 2.62% 提升至 19.02% 和 20.00%。因此后续算法应把图标语义与相似候选区分作为独立问题，而不能只继续放大图像。

8 错误分解：目标覆盖与局部判别

768px KDE-grid 留出集共有 408 个失败。将 GT 框映射到裁剪窗口后，可以把失败分为目标完全不可见、部分可见但中心在窗口外，以及中心可见后仍然误判。该分解只使用几何信息，不把模型置信度当作错误原因。

表 **8:** 768px KDE-grid 留出集失败分解（总失败数 408）

错误类型	样本数	占失败比例	该覆盖率下的总体命中率
目标与窗口无交集	164	40.20%	0/164
部分可见、中心在窗口外	8	1.96%	3/11
目标中心可见但仍失败	236	57.84%	380/616

图标的 305 个样本中，108 个完全未覆盖、3 个部分覆盖且中心在外、133 个在中心可见后失败；文本对应为 56、5 和 103 个。对每类各 12 个中心可见失败进行视觉抽查，还观察到同一控件边缘的框外点，以及选到相邻或功能相近控件的情况。该抽查用于解释错误形态，不作为总体比例估计。校准集四种局部读出的 Pass@4 为 51.90%，高于 KDE-grid 的 47.34%；这些读出是确定性候选而非独立采样，Pass@4 只表示候选上限，不能当作可部署 top-1。

9 顺序缩放与双局部视图

9.1 实验设计与校准结果

顺序缩放比较两条路径：直接路径以全图 default 为中心读取小窗口；顺序路径先执行既有 768px KDE-grid，再以该点为中心读取同尺寸小窗口。校准集扫描 256、384、512px 及 default/KDE-grid，最终选择 512px KDE-grid。其校准命中率为 48.99%，直接 512px 为 44.81%，配对提

升 4.18 个百分点（95% CI $[1.65, 6.71]$，$p = 0.00166$）；相对 768px 基线仅提高 1.65 个百分点，因此仍需留出验证。

双视图保留上述 default 居中的 768px 窗口，并在全图外积 KDE 上寻找第二个空间模式。设默认点为 g，平滑后的二维密度为 D，候选网格点为 c，则第二中心满足

$$a = \arg \max_{c:\|c-g\|_2 \geq 0.1} D(c). \tag{2}$$

局部 5×5 加权质心若落回阈值内，则回退到合格的峰值格点。全量 1581 个最终中心均通过距离检查。第二视图同样使用 768px；若边界裁剪后与第一窗口相同则复用，不重复前向。校准集在两个局部读出和三个置信度分数中选择，最终为 KDE-grid 与 `score=top1+spatial`，分数较高者作为 top-1。校准命中率为 50.13%，相对基线提高 2.78 个百分点（95% CI $[1.14, 4.56]$，$p = 0.00164$），Pass@2 为 53.92%。

9.2　独立留出结果

所有方法共享同一 791 条留出样本；尺寸、读出和选择规则均在查看留出预测前确定。

表 **9:** 顺序缩放与双视图的留出集比较

方法	Hit@1	相对 768px	McNemar p	CPU 中位时间	新增局部读取
768px KDE-grid	48.42%	—	—	2.40s	0
直接 512px KDE-grid	45.51%	-2.91 pp	0.0329	2.32s	1/样本
768→512px KDE-grid	50.95%	+2.53 pp	0.0519	3.31s	1/样本
双 **768px** 视图	**52.34%**	**+3.92** pp	$\mathbf{9.26 \times 10^{-6}}$	3.31s	732/791

直接缩小窗口显著损害精度，说明覆盖损失可以超过局部分辨率收益。顺序缩放相对直接 512px 提高 5.44 个百分点（95% CI $[2.78, 8.09]$，$p = 1.01 \times 10^{-4}$），证明逐级定位优于直接缩小；但其相对 768px 基线只修复 58 条、回退 38 条，$p = 0.0519$，净收益处于显著性边界。三个确定性候选的 Pass@3 为 58.03%，同样不是实际 top-1。

双视图修复 40 条、回退 9 条，提升的 95% CI 为 $[2.28, 5.69]$ 个百分点。第二视图单独仅为 41.72%，说明收益来自两视图互补及选择，而非备选模式普遍更好。Pass@2 为 55.25%，与最终 52.34% 仍有 2.91 个百分点的选择差距。目标中心联合覆盖率从 77.88% 升至 82.05%，新增覆盖 33 个样本；其余收益来自重叠区域的二次判别。双视图比顺序缩放高 1.39 个百分点，但直接配对区间为 $[-1.26, 3.92]$，$p = 0.338$，两者优劣尚不能确定。

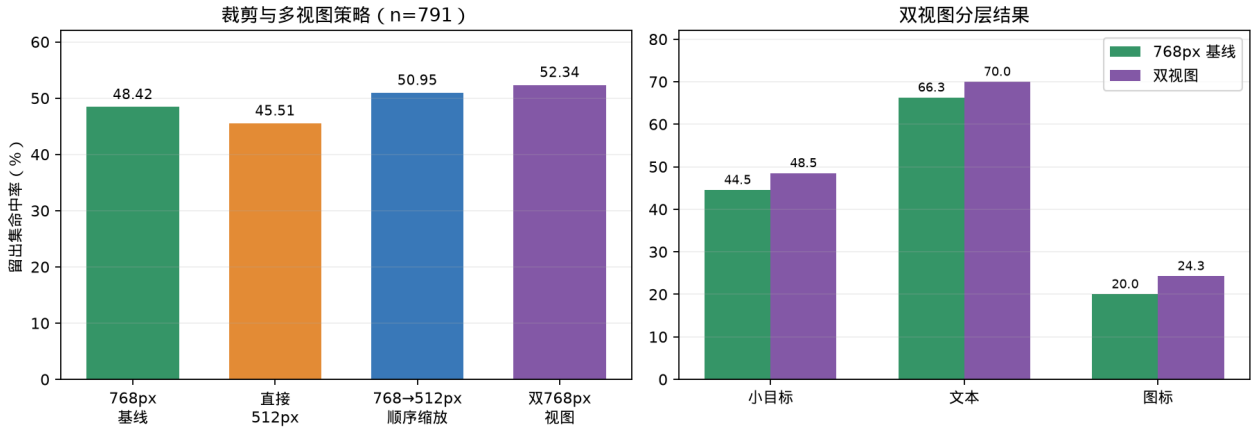


图 **5:** 统一留出集上的裁剪、多视图及分层结果。所有柱均为实际 top-1，不包含 Pass@K 候选上限。

双视图将小目标从 44.51% 提升至 48.48%（$p = 4.23 \times 10^{-5}$），文本从 66.26% 提升至 69.96%（$p = 0.00143$），图标从 20.00% 提升至 24.26%（$p = 0.00443$）。顺序缩放对应结果为 47.26%、68.11% 和 23.61%。图标仍远低于文本，是最明显的剩余瓶颈。表中 CPU 时间是本地运行的量级观测，不是控制并发的延迟基准；跨策略比较应同时参考实际模型读取次数。

10 问题 1 专项：二维联合分布解法验证

10.1 条件链式读取：形式正确，但实证无效

训练模板中，y 的预测位置之前存在真实 x token，而原单次推理把 x 保留为占位符。由此可以回填候选 x，读取条件分布并构造截断联合：

$$J_K(x,y) = Z^{-1}\mathbf{1}(x \in \mathcal{C}_K)\, p(x)p(y \mid x), \qquad Z = \sum_{x \in \mathcal{C}_K, y} p(x)p(y \mid x). \tag{3}$$

候选按 $p(x)$ 降序并做 4-bin 非极大值抑制，同一运行评估 $K = 1, 2, 4, 8$；联合读出包括 MAP、区域期望和 KDE。默认读取接口经逐概率检查与旧实现一致，条件路径也产生了实际分布变化，并非实现上的恒等输出。

128 条 pilot 上，独立 default/KDE 分别为 11.72%/15.62%，最佳条件联合 $K = 4$ KDE 为 14.06%，没有改善；$K = 8$ 同为 14.06%，但候选 Pass@8 达 23.44%。简单置信度排序、x 温度校准和独立/条件混合分布均未超过独立 KDE。扩大候选也没有趋势：相同 32 条上 $K = 16$ 的联合 KDE 为 18.75%，仍低于独立 KDE 的 21.88%，尽管 Pass@16 为 31.25%。768px 局部 pilot 中条件联合最佳为 40.62%，与原局部 KDE 相同。

更重要的是，$K = 8$ 仅选中 14.84% 样本的 GT x bin；在这些样本中，条件联合相对独立外积的 GT 对数似然平均下降 0.116，只有 31.58% 样本改善。说明瓶颈不仅是候选覆盖或选择，也包括现有条件信号本身。由于 pilot 已明确否定收益，未再消耗全量留出算力。该结果不能证明链式分解错误，而是说明在当前模型、候选预算和分布质量下，它不是有效解法。

10.2 冻结特征上的直接二维区域监督

第二条路径是在 final normalization 后提取槽位隐藏向量，训练轻量区域头。校准集前 632 条训练、后 158 条验证并选择 epoch，再用全部 790 条按该 epoch 重拟合，最终在 791 条留出样本评估。特征标准化只由相应训练数据估计。比较三种输出：

- 独立轴头：分别预测 16 个 x 区域和 16 个 y 区域；
- 完整联合头：直接预测 256 个二维区域；
- 低秩联合头：$p(x,y) = \sum_r \pi_r u_r(x) v_r(y)$，$r = 4$，以真正的联合 NLL 训练，而不是逐槽独立 CE。

三者都带 cell 内 sigmoid offset，使用相同 MLP、训练样本和验证协议；另以无线性隐藏层的版本检查模型容量影响。

表 **10:** 冻结特征区域头的留出结果（$n = 791$，原 default 为 13.91%）

特征与输出头	独立轴	完整联合	低秩联合
仅 y-slot，MLP	5.44%	3.29%	0.51%
$x + y$ slots，MLP	**6.70%**	5.69%	1.26%
仅 y-slot，线性	4.05%	2.78%	0.88%

增加 x 特征确实改善三种头，但独立轴始终最好，全部低于原 default。过拟合也很明显：仅 y 特征的 MLP 重拟合后，独立头在全部校准样本上达到 51.27%，完整联合头为 31.39%，留出却分别只有 5.44% 和 3.29%；去掉隐藏层并未改善。由此只能得出少量校准数据上的冻结特征联合监督泛化失败，不能推出二维联合监督在充分训练数据下无效。

10.3 官方二维 patch-attention 模型对照

为区分方法方向与本模型改造失败，进一步调用官方 GUI-Actor-2B-Qwen2-VL。该模型以专用 token 对视觉 patch 形成二维注意力区域，可在一次前向产生多个候选，并提供 verifier 路线 [4]。本地使用官方 Transformers 4.51.3 和未修改的官方推理代码。

在相同的 32 条样本上，1MP 输入的 top-1 仅为 9.38%（3/32），Pass@3 为 12.50%，低于槽位 default 的 15.62% 和 KDE 的 21.88%；CPU 中位耗时约 46.85s/条。随后完成官方约 3200×1800 等效像素的 8 条小样本：top-1 和 Pass@3 均为 50.00%（4/8），相同 8 条的 1MP 仅为 12.50%，槽位 default/KDE 均为 25.00%；CPU 中位耗时约 570.64s/条。该结果支持高分辨率二维区域方法的方向，但样本量很小，不能当作全量 benchmark 分数，论文中的 36.7%/41.8% 也不代替本地复现。

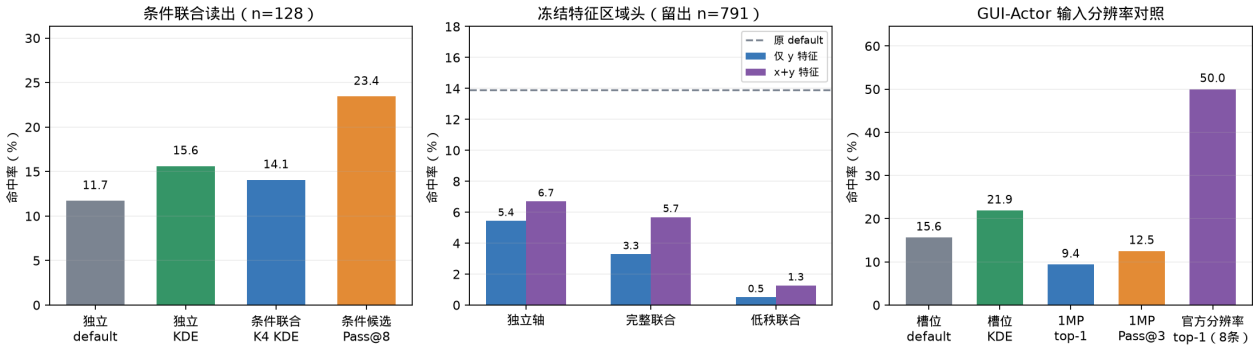


图 **6:** 问题 1 专项结果。左：条件联合 pilot；中：相同冻结特征和留出协议的区域头；右：GUI-Actor 分辨率对照，1MP 使用 32 条，官方分辨率使用 8 条。Pass@K 均为候选上限，不是实际 top-1。

10.4 专项结论

本轮没有找到适用于当前 GUI-Decisions-2B 的联合读出改进。条件链式读取、完整/低秩联合头和线性头均未超过独立轴基线，当前仍应保留独立轴 KDE 与双视图作为实际参照。GUI-Actor 的 8 条官方分辨率小样本则支持直接二维区域方法，但不能外推为全量结果。可检验的后续解法不是在现有槽位上继续调参，而是以更大规模、覆盖更多应用和分辨率的数据直接训练二维 patch heatmap/区域 head，并配套训练候选 verifier。条件联合失败说明接口形式上的联合概率并不等于有用的空间表示；冻结头失败说明监督数据量和泛化同样关键。

11 讨论

11.1 证据链与算法含义

围绕最初提出的三个结构性问题，本轮实验形成以下结论，并区分直接证据与尚待验证的解释：

1. 独立 **x/y** 槽位缺少真正的二维联合分布：问题成立，但未找到部署解法。 expected 在全图上只有 6.58%，KDE-grid 无需新前向达到 17.96%，说明逐轴读出确实损失空间结构。外积 KDE 的备选模式经第二视图验证具有互补价值，但第二视图单独只有 41.72%。专项实验

又否定了条件链式读取和小样本冻结联合头，说明接口上的联合概率与有效的联合空间表示不是同一回事。

2. 点监督不等于可执行区域和功能语义：仍是未解决的核心问题。 408 个失败中 236 个发生在目标中心可见之后；视觉抽查又发现同控件边缘与相邻控件误判。双视图将图标提至 24.26%，仍远低于文本的 69.96%。这些现象与区域监督、功能语义及困难负例不足一致，但本轮未在完整模型上系统操纵训练目标，不能精确分解语义、局部视觉与标注噪声的贡献。
3. 全图单视图链路丢失局部视觉证据：得到最强验证。真实像素裁剪从全图 13.41% 跃升至 47.88%，顺序缩放与双视图在留出集继续达到 50.95% 和 52.34%，远大于纯坐标后处理收益。这验证的是输入尺度、上下文和单视图覆盖的综合瓶颈，尚不能单独归因于视觉降采样、token 合并或语言侧单步读出中的某一个环节。

因此，推理时搜索主要缓解第一和第三个问题，并未解决第二个问题。直接 512px 的回退说明分辨率、上下文和覆盖必须共同优化；Pass@K 与实际 top-1 的差距又说明候选生成和候选选择应分别评估。这些结果与 GUI-Actor、GUI-AIMA 的二维区域监督方向 [4, 5]、UI-Zoomer 的不确定性搜索 [6] 以及 Seg2Click 的子 token 区域预测 [7] 相互呼应。本文没有复现这些模型的训练结果，相关文献仅用于解释后续研究方向。

11.2 局限性

- 仅实测 2B 模型；31B、其他 backbone、完整模型的联合训练和强化学习未验证。轻量区域头只在 790 条校准数据上训练，存在明显过拟合，不能代表充分数据下的联合监督效果。
- GUI-Actor 完成 32 条 1MP 和 8 条官方分辨率对照，后者 CPU 中位耗时约 570.64s/条；小样本不能外推为全量结果，论文分数也不能替代本地复现。
- vanilla 使用 agent/tool-call 提示词，不是专用 grounding 提示词；不能据此声称所有公平提示条件下槽位都优于 vanilla。
- 原始 ScreenSpot 与 ScreenSpot-v2 的标注不同，本文不将 76.49% 与近期 v2 分数直接比较。
- RefCOCO 使用新的点定位协议，不能与文章附录的 box IoU 直接比较；小目标集合也不代表极小物体。
- 128 条 pilot 仅用于探索；核心结论以 ScreenSpot-Pro 全量结果及一次固定的 790/791 校准留出划分为主，尚无多随机划分或外部数据集复核。分层显著性为次要分析。
- 视觉错误抽查每类只有 12 条，用于定性解释，不用于估计背景、相邻控件或标注边缘错误的总体比例。
- 延迟全部来自 CPU，未验证 vLLM/SGLang、GPU 并发、prefix cache 或文章所述 NVFP4 服务性能；本轮新增策略也未做控制并发的专项延迟测试。
- Hit@1 不等于在线 agent 任务成功率；尚未执行 OSWorld/WebArena 端到端验证。
- $p_x p_y$ 是联合分布近似。要彻底解决二维歧义，需要联合 heatmap、区域 head 或子 token mask，而非继续调 KDE 参数。

11.3 后续实验建议

短期保留 768px KDE-grid 作为统一基线，以双视图 52.34% 作为新的推理时参照，在同 backbone、同训练数据下比较独立 x/y bins、16×16 joint-region 加局部 offset、二维 patch heatmap 和子 token mask。联合目标必须优化二维 NLL/KL 或区域 BCE+Dice，不能退化为

四个独立数字槽。图标侧应加入同屏 target–distractor 困难负例与功能语义数据，并检查文本是否回退。中期可学习轻量 crop reranker 以缩小 Pass@K 与 top-1 差距；长期需在统一 GPU 服务上测量端到端延迟，并在 OSWorld/WebArena 验证在线收益。

12 可复现性与实验产物

原始结果保存在 `results/`，核心文件包括：

- `local_gui-decisions-2b_click_0.json`：ScreenSpot 全量复现。
- `gui-owl-vanilla-s0of10_click_128.json`：vanilla 配对对照。
- `refcoco-slots-s0_refcoco_point_128.json` 及对应 vanilla、seed 1 和 small 文件：自然图像外推。
- `zoom-sspro-full-default-s0_screenspot-pro_zoom_1581.json`：ScreenSpot-Pro 全图与 512px 全量结果。
- `crop-sweep-calibration-s0_790.json`：尺寸与局部读出校准扫描。
- `crop-heldout-768-kdegrid-s0_791.json`：预选组合留出验证。
- `crop-sweep-final-s0.json`：校准、留出和合并统计分析。
- `crop-errors-768-s0.json`：目标覆盖与局部误判分解。
- `recursive-zoom-final-s0.json`：顺序缩放与直接小窗口的校准和留出比较。
- `multiview-final-v2-s0.json`：双视图候选、置信度选择、覆盖和分层结果。
- `multiview-vs-recursive-heldout-s0.json`：两种新策略的直接配对比较。
- `conditional-joint-pilot-k8-sep4-s0_128.json`：条件联合原始预测与候选。
- `conditional-joint-pilot-analysis-s0.json`：条件联合读出、候选上限和分布统计。
- `joint-region-heads-y-refit-final-v2-s0.json`：单槽冻结特征区域头留出结果。
- `joint-region-heads-xy-final-s0.json`：双槽冻结特征区域头留出结果。
- `gui-actor-2b-1mp-pilot-s0_32.json`：官方 GUI-Actor 的 1MP 小样本对照。
- `gui-actor-2b-official-res-pilot-s0_8.json`：官方分辨率小样本及耗时。

主要实现为 `slotread/zoom.py`、`scripts/check_zoom_local.py`、`scripts/check_crop_sweep_local.py`、`scripts/analyze_zoom.py` 和 `scripts/analyze_crop_sweep.py`。本轮新增 `scripts/check_recursive_zoom_local.py`、`scripts/check_multiview_local.py` 及对应分析脚本；`scripts/analyze_crop_errors.py` 和 `scripts/make_error_audit.py` 分别生成几何分解和视觉抽查。问题 1 专项使用 `slotread/joint.py`、`scripts/check_conditional_joint_local.py`、`scripts/extract_sspro_features.py`、`scripts/train_joint_region_head.py` 和 `scripts/check_gui_actor_local.py`；GUI-Actor 使用官方 4.51.3 环境和 ModelScope 权重。报告图表由 `scripts/generate_report_figures.py` 从原始 JSON 重新生成。实验已通过结果完整性、有序划分、最终候选距离、坐标/分布冒烟和设备一致性检查，以及独立代码审查、`compileall`、`git diff --check` 和 `uv build`。早期双视图质心未严格满足距离阈值的部分结果，以及低秩预测转置解码产生的指标均已弃用，本报告仅使用修正后的完整运行。

参考文献

[1] Umapathi, Logesh Kumar. GUI-Decisions: Stop Decoding Coordinates for 3x Faster Computer-Use Grounding. 2026. https://huggingface.co/blog/infinitylogesh/gui-decisions-stop-decoding-coordinates

[2] Li, Kaixin et al. ScreenSpot-Pro: GUI Grounding for Professional High-Resolution Computer Use. 2025. https://arxiv.org/abs/2504.07981

[3] RefCOCO evaluation data, lmms-lab-encoder/RefCOCO. https://huggingface.co/datasets/lmms-lab-encoder/RefCOCO

[4] Wu et al. GUI-Actor: Coordinate-Free Visual Grounding for GUI Agents. NeurIPS 2025. https://arxiv.org/abs/2506.03143

[5] Zhou et al. GUI-AIMA: Coordinate-Free GUI Grounding via Intrinsic Multimodal Attention. 2026. https://arxiv.org/abs/2511.00810

[6] Chen et al. UI-Zoomer: Training-Free Adaptive Zoom-In for GUI Grounding. 2026. https://arxiv.org/abs/2604.14113

[7] Huang et al. Seg2Click: Executable-Region Prediction for GUI Grounding. 2026. https://arxiv.org/abs/2610.16234

[8] ReLaViS: Recurrent Latent Visual Search for GUI Grounding. 2026. https://arxiv.org/abs/2610.05185